

Universidad de Sevilla  
Máster en Ingeniería de Electrónica, Robótica y Automática (MIERA)

Percepción en Automática y Robótica

---

# Simulación de Coche Autónomo: Detección de Carriles y Señales

---

*Grupo XI*

Samuel Boleslaw Locoche  
Víctor Javier Granero Gil  
José Francisco López Ruiz

Curso 2025–2026

# Índice

|                                                                                           |           |
|-------------------------------------------------------------------------------------------|-----------|
| <b>1. Introducción</b>                                                                    | <b>3</b>  |
| <b>2. Detección de carriles</b>                                                           | <b>3</b>  |
| 2.1. Primer enfoque: estimación mediante líneas horizontales . . . . .                    | 4         |
| 2.2. Enfoque basado en segmentación semántica . . . . .                                   | 5         |
| 2.2.1. Encoder VGG16 . . . . .                                                            | 5         |
| 2.2.2. Decoder U-Net . . . . .                                                            | 5         |
| 2.2.3. Bloque convolucional . . . . .                                                     | 6         |
| 2.3. Entrenamiento del modelo . . . . .                                                   | 6         |
| 2.4. Resultados Seguimiento de Carriles . . . . .                                         | 7         |
| <b>3. Detección y clasificación de señales</b>                                            | <b>8</b>  |
| 3.1. Detección de las señales . . . . .                                                   | 8         |
| 3.2. Clasificación de las señales . . . . .                                               | 10        |
| 3.2.1. Datasets utilizados . . . . .                                                      | 10        |
| 3.2.2. Arquitectura de la red neuronal . . . . .                                          | 11        |
| 3.2.3. Resultados de los entrenamientos . . . . .                                         | 11        |
| 3.2.4. Test sobre señales de la simulación . . . . .                                      | 12        |
| <b>4. Integración en simulación y resultados</b>                                          | <b>13</b> |
| 4.1. Entorno de simulación: CARLA Simulator . . . . .                                     | 13        |
| 4.2. Arquitectura del sistema . . . . .                                                   | 14        |
| 4.3. Infraestructura: Docker y contenedores . . . . .                                     | 15        |
| 4.4. Nodos ROS2 del sistema . . . . .                                                     | 15        |
| 4.4.1. Nodo de detección de carriles ( <code>lane_detection_node</code> ) . . . . .       | 16        |
| 4.4.2. Nodo de detección de señales ( <code>sign_detection_node</code> ) . . . . .        | 16        |
| 4.4.3. Nodo de control del vehículo ( <code>vehicle_control_node</code> ) . . . . .       | 16        |
| 4.4.4. Nodo generador de anotaciones ( <code>annotation_generator_node</code> ) . . . . . | 17        |
| 4.5. Generación de datasets sintéticos . . . . .                                          | 18        |
| 4.6. Resultados . . . . .                                                                 | 19        |
| 4.6.1. Rendimiento en tiempo real . . . . .                                               | 19        |
| 4.6.2. Entorno de pruebas . . . . .                                                       | 19        |
| 4.6.3. Conducción autónoma en simulación . . . . .                                        | 19        |
| <b>5. Conclusiones</b>                                                                    | <b>19</b> |

### Resumen

Este trabajo presenta el diseño e implementación de un sistema de percepción para un vehículo autónomo simulado en *CARLA Simulator*, integrado con *ROS2 Humble* mediante contenedores Docker. El sistema comprende tres módulos principales: detección de líneas de carril mediante una red de segmentación semántica VGG16–U-Net, clasificación de señales de tráfico a través de una CNN entrenada con PyTorch, y un sistema de integración que une ambos módulos con un controlador PID doble para la conducción autónoma. El código fuente, modelos entrenados, datasets y vídeos demostrativos se encuentran en el repositorio público de GitHub: <https://github.com/JoseLopez36/Navegacion-Deteccion-Senales>.

## 1. Introducción

La conducción autónoma es uno de los retos tecnológicos más ambiciosos de la última década. Para que un vehículo sea capaz de desplazarse sin intervención humana debe ser competente en varias etapas: percepción del entorno, planificación de trayectoria y actuación sobre los sistemas de control. Este trabajo aborda la etapa de *percepción*, responsable de extraer información útil del entorno a partir de los datos sensoriales.

El objetivo del proyecto es desarrollar un sistema de percepción y control básico para un vehículo autónomo simulado en *CARLA Simulator*, conectado a través de *ROS2 Humble*. El flujo de funcionamiento diseñado es el siguiente:

1. Adquisición de imágenes desde la cámara virtual de CARLA.
2. Detección de líneas de carril mediante un modelo de segmentación semántica (VGG16-U-Net con TensorFlow/Keras), y estimación del error lateral del vehículo.
3. Detección y reconocimiento de señales de tráfico mediante una CNN implementada en PyTorch.
4. Interpretación de las señales para adaptar la velocidad del vehículo.
5. Publicación de comandos de control hacia CARLA.

Todo el código fuente, modelos entrenados, datasets y material multimedia (imágenes y vídeo demostrativo) están disponibles en el repositorio público de GitHub del proyecto:

<https://github.com/JoseLopez36/Navegacion-Deteccion-Senales>

### Estructura de la memoria

La memoria se organiza en tres bloques principales:

**Sección 2: Detección de carriles.** Describe el dataset empleado, la arquitectura VGG16-U-Net y los resultados del modelo de segmentación.

**Sección 3: Detección y clasificación de señales.** Explica el proceso de detección por imagen y el diseño y entrenamiento de la CNN clasificadora.


**Sección 4: Integración en simulación y resultados.** Desarrolla la arquitectura software completa en CARLA/ROS2, el control del vehículo y los resultados obtenidos en simulación.

## 2. Detección de carriles

Uno de los objetivos principales de este proyecto es la detección de las líneas de carril a partir de imágenes capturadas por una cámara frontal. Para ello se han evaluado diferentes enfoques basados en visión artificial y aprendizaje profundo, con el objetivo de obtener una representación fiable de la posición de los carriles que posteriormente pueda utilizarse para tareas de guiado y seguimiento.

Para el entrenamiento y validación de los modelos se ha utilizado el dataset TuSimple, uno de los conjuntos de datos de referencia en el ámbito de la detección de carriles para conducción autónoma.

El dataset proporciona imágenes capturadas desde una cámara frontal instalada en un vehículo, así como la posición anotada de las líneas de carril presentes en cada escena.



(a) Imagen ejemplo del dataset.

(b) Máscara generada a partir de JSON.

Figura 1: Ejemplo de una imagen del conjunto de datos y la máscara de segmentación obtenida a partir de sus anotaciones en formato JSON.

## 2.1. Primer enfoque: estimación mediante líneas horizontales

Como primera aproximación se intentó reproducir la metodología propuesta por Yoo et al.<sup>1</sup>, basada en la representación de los carriles mediante una serie de puntos obtenidos a partir de múltiples líneas horizontales distribuidas sobre la imagen.

La idea principal consiste en dividir la imagen en diferentes franjas horizontales y estimar para cada una de ellas la posición horizontal de las líneas de carril. De este modo, el carril queda representado como una sucesión de puntos que posteriormente pueden unirse para reconstruir la geometría de los carriles.

Debido a las limitaciones computacionales y al tamaño del modelo utilizado, inicialmente se emplearon únicamente entre ocho y diez líneas horizontales distribuidas a lo largo de la imagen.

Sin embargo, esta resolución resultó insuficiente para describir adecuadamente la geometría de los carriles. En situaciones con curvas pronunciadas o cambios de perspectiva, la cantidad de puntos obtenida era demasiado reducida para reconstruir de forma precisa la trayectoria de las líneas.

Tras diversas pruebas se comprobó que los resultados obtenidos no alcanzaban el nivel de precisión requerido para el seguimiento fiable del vehículo, por lo que se decidió explorar un enfoque alternativo basado en segmentación semántica.

<sup>1</sup>Yoo, S., Lee, H., Myeong, H., Yun, S., Park, H., Cho, J., & Kim, D. H. (2020). *End-to-End Lane Marker Detection via Row-wise Classification*. arXiv:2005.08630.

## 2.2. Enfoque basado en segmentación semántica

La segunda aproximación consistió en reformular el problema como una tarea de segmentación semántica binaria.

En lugar de estimar únicamente una serie de puntos representativos, el objetivo pasa a ser clasificar cada píxel de la imagen indicando si pertenece o no a una línea de carril.

Esta estrategia permite obtener una representación mucho más detallada de la escena y facilita la posterior extracción de la geometría del carril.

Para este propósito se desarrolló una arquitectura basada en U-Net utilizando VGG16 como encoder.

La arquitectura implementada combina dos componentes principales:

- Encoder basado en VGG16.
- Decoder basado en U-Net.

El encoder se encarga de extraer características visuales de la imagen, mientras que el decoder reconstruye progresivamente una máscara de segmentación con la misma resolución que la imagen de entrada.

### 2.2.1. Encoder VGG16

Se ha utilizado la arquitectura VGG16 preentrenada sobre ImageNet mediante técnicas de transfer learning.

El uso de pesos preentrenados permite aprovechar características visuales previamente aprendidas, tales como bordes, texturas y patrones geométricos, reduciendo el tiempo de entrenamiento y mejorando la capacidad de generalización.

Durante el proceso de entrenamiento se permitió el ajuste de todos los parámetros de la red para adaptarlos específicamente a la detección de carriles.

Las capas seleccionadas del encoder se utilizan posteriormente en las conexiones de salto (skip connections) características de la arquitectura U-Net.

### 2.2.2. Decoder U-Net

El decoder reconstruye progresivamente la resolución espacial perdida durante el proceso de compresión realizado por el encoder.

Para ello se utilizan operaciones de upsampling que duplican la resolución de los mapas de características en cada etapa.

Posteriormente, dichos mapas se concatenan con la información procedente de las capas equivalentes del encoder mediante skip connections.

Estas conexiones permiten recuperar detalles espaciales finos que resultan fundamentales para delimitar con precisión las líneas de carril.

### 2.2.3. Bloque convolucional

Tras cada operación de concatenación se aplica un bloque convolucional compuesto por:

- Convolución  $1 \times 1$ .
- Convolución  $3 \times 3$ .
- Activación ELU.
- Batch Normalization.
- Dropout.

La convolución  $1 \times 1$  permite reorganizar y combinar la información procedente de los distintos canales de características.

Posteriormente, la convolución  $3 \times 3$  analiza las relaciones espaciales locales y permite detectar patrones relevantes para la identificación de los carriles.

La activación ELU introduce no linealidad en el modelo y mejora la estabilidad del aprendizaje frente a funciones de activación tradicionales como ReLU.

La capa Batch Normalization normaliza las activaciones de la red, acelerando la convergencia durante el entrenamiento y mejorando la robustez del modelo.

Finalmente, se incorpora una capa Dropout con una tasa del 25 %, utilizada como mecanismo de regularización para reducir el sobreajuste.

## 2.3. Entrenamiento del modelo

Para entrenar el modelo fue necesario transformar las anotaciones proporcionadas por TuSimple en máscaras binarias de segmentación.

Cada máscara contiene información pixel a pixel indicando las regiones pertenecientes a las líneas de carril. Estas máscaras constituyen la salida esperada durante el proceso de entrenamiento supervisado.

El entrenamiento se realizó utilizando imágenes redimensionadas a una resolución de  $224 \times 224$  píxeles.

Durante el proceso de aprendizaje, la red recibe como entrada una imagen de carretera y genera una máscara de probabilidad donde cada píxel representa la probabilidad de pertenecer a una línea de carril.

La salida final se obtiene aplicando una función de activación sigmoide y un umbral de decisión para convertir dichas probabilidades en una máscara binaria.

Para el entrenamiento del modelo se han realizado 10 épocas de entreno. Las curvas de aprendizaje del modelo de precisión y pérdida se han representado en la Figura 2. En ellas se puede observar como se ve mejorado el rendimiento del modelo conforme nuevas épocas son resueltas.




Figura 2: Resultados Épocas del entrenamiento

## 2.4. Resultados Seguimiento de Carriles

En esta sección se presentan los resultados obtenidos por el modelo de detección de carriles en distintos escenarios de prueba.

En primer lugar, se muestra una predicción sobre una carretera recta, donde el modelo es capaz de identificar de forma estable la estructura del carril sin presentar desviaciones significativas.




Figura 3: Predicción de un Carril recto

En segundo lugar, se analiza una predicción en un tramo con una ligera curva. En este escenario se observa que el modelo mantiene un buen seguimiento de la trayectoria del carril, adaptándose correctamente a la curvatura sin perder continuidad, lo que indica una adecuada capacidad de generalización ante variaciones suaves en la geometría de la carretera.






Figura 4: Predicción de Carril con ligera Curva

Por último, se incluye una comparación entre la predicción del modelo y la máscara real correspondiente. En este caso se aprecia una alta similitud entre ambas, con una buena coincidencia en la forma y posición de los carriles. No obstante, se observan pequeñas desviaciones en algunas zonas, debidas a elementos presentes en la imagen.




Figura 5: Comparación de una imagen de ejemplo con su máscara real y la predicción del modelo

### 3. Detección y clasificación de señales

Una vez que el vehículo puede seguir el carril, tiene que respetar las reglas del código de circulación, para evitar accidentes. Entonces, el vehículo tiene que ser capaz de detectar y reconocer las señales. En esta parte, se tratan de tres señales de velocidad: 30  $km/h$ , 60  $km/h$  y 90  $km/h$ . Se verá en las secciones siguientes cómo el vehículo detecta las señales, y cómo reconoce señales de velocidad mediante una red neuronal convolucional.

#### 3.1. Detección de las señales

Cuanto a la detección de las señales, se utiliza el modulo *OpenCV* de python para tratar las imágenes. En esta sección se descomponen los diferentes pasos para detectar una señal. La Figura 6 ilustra una imagen que podría venir de la cámara del vehículo,

y que el algoritmo de detección recibe como entrada.



Figura 6: Imagen de entrada de la detección, sobre la cual se realizará los diferentes pasos de detección.

En primer lugar, se hace una detección de todas las zonas rojas en la imagen. En efecto, las tres señales tienen como color distintivo el rojo. Se convierte la imagen en el formato HSV (más robusto contra los cambios de luz), y se realiza la detección del rojo mediante máscaras. La Figura 7 muestra la máscara conseguida después de este paso.



Figura 7: máscara conseguida mediante la detección del color.

Una vez que todas las zonas rojas están detectadas, se detectan sus contornos. El objetivo es retener la zona con la area mayor, porque si hay una señal en la imagen, corresponde a esta zona. Sin embargo, se define una area mínima de detección. Si la zona mayor tiene una area menor que esta area mínima, se considera que la imagen es vacía de toda señal.

Si se detecta una señal, se crea una bounding box alrededor de ella y se zooma en esta bounding box. Este zoom constitua el resultado de la detección, que permitirá la red neuronal clasificar la señal detectada.



(a) Bounding box alrededor de la señal.



(b) Zoom sobre la señal.

Figura 8: Resultados de la detección

## 3.2. Clasificación de las señales

Ahora que el vehículo es capaz de detectar la presencia o la ausencia de una señal, tiene que reconocerla para que adapte su velocidad a la situación. En esta parte, se tratarán de la arquitectura CNN del modelo así como los datasets utilizados para entrenarlo y validarlo. Se analizarán los resultados para identificar las ventajas y los inconvenientes de este modelo.

### 3.2.1. Datasets utilizados

Se utiliza el *German Traffic Sign Recognition Benchmark* (GTSRB): <http://benchmark.ini.rub.de/?section=gtsdb&subsection=news>

Este dataset contiene varios tipos de señales, como señales de velocidad, de dirección, etc. Sin embargo, no tiene señales de 90 *km/h*, entonces se lo utiliza para las señales de 30 *km/h* y 60 *km/h*.

Para crear un dataset de entrenamiento con señales de 90 *km/h*, se crea en primer lugar un pequeño dataset con imágenes que se encuentran en la red. Una vez que se tiene unas imágenes (alrededor de 70 imágenes), se utiliza un script Python para aplicar transformaciones en las imágenes, como rotaciones o cambios de luz. Al final, se obtiene 500 imágenes.

Se podrían obtener más imágenes mediante estas transformaciones, para alcanzar 1500 imágenes y tener un dataset equilibrado. No obstante, este dataset provocaría un overfitting sobre la clase de las señales de 90 *km/h*. En efecto, aunque hubiera más imágenes, estas se basarían en un pequeño conjunto de 70 imágenes. Al final, este dataset aprendería estas 70 imágenes de memoria. Por lo tanto, se eligió crear menos imágenes para conseguir mejores resultados.

En cuanto a los datasets de validación, se aplica el mismo método para obtener una parte con señales de 90 *km/h*. Pero en este caso, no se importa el problema anterior ya que el modelo no va a modificar sus pesos con este dataset. Entonces se obtiene al

final un dataset de validación con 720 imágenes para cada tipo de señal.

Por fin, el dataset de test se compone unicamente de imágenes que provienen de la simulación, con 22 imágenes para cada tipo de señal.

El Cuadro 1 resume el contenido de cada dataset.

| Dataset                                                                           | Entrenamiento | Validación | Test |
|-----------------------------------------------------------------------------------|---------------|------------|------|
|  | 1500          | 720        | 22   |
|  | 1360          | 720        | 22   |
|  | 500           | 720        | 22   |

Cuadro 1: Número de imágenes para cada dataset y cada señal.

### 3.2.2. Arquitectura de la red neuronal

Se ha creado una red neuronal convolucional mediante el módulo *PyTorch*. El modelo tiene que reconocer la señal en una imagen en color de tamaño 96x96. Como todo modelo CNN, este modelo puede dividirse en dos partes:

- La parte convolucional que se compone de cuatro capas convolucionales con un kernel 3x3 y entre cada capa una capa de MaxPooling de tamaño 2 para reducir el número de datos, y por lo tanto el número de cálculos.
- La parte de clasificación que se compone de tres capas densas. Las dos primeras incluyen una capa de Dropout para reducir el overfitting, y la capa de salida tiene 3 neuronas, una para cada clase.

Entre ambas partes, una capa Flatten permite aplanar los datos para conseguir una entrada válida para las capas densas.

La Figura 9 ilustra la arquitectura del modelo.

### 3.2.3. Resultados de los entrenamientos

En la Figura 10 se muestran los resultados de un entrenamiento del modelo con 23 épocas. Se observa que las pérdidas y la eficiencia se estabilizan al final del entrenamiento. Sin embargo, durante el entrenamiento, las pérdidas y la eficiencia varían de manera significativa. Estas variaciones pueden explicarse por las capas de Dropout. En efecto, en nuestro modelo, estas capas desactivan las neuronas con una probabilidad de 0.3 para luchar contra el overfitting. Esto obliga al modelo a encontrar diferentes maneras reconocer las características de la imagen.




Figura 9: Arquitectura del modelo CNN que se utiliza para clasificar las señales




Figura 10: Resultados de un entrenamiento con la evolución de las pérdidas a la izquierda, y de la eficiencia a la derecha

Varios otros entrenamientos han sido efectuados con varios valores de épocas. Si el número de épocas supera 25, un overfitting aparece y los resultados sobre la clase de señales de 60 *km/h* son muy bajos. Al otro lado con menos épocas, las pérdidas y la eficiencia varían demasiado como se observa en la Figura 10.

### 3.2.4. Test sobre señales de la simulación

Antes de comprobar este modelo en la simulación, se lo comprueba con un dataset de Test con señales que provienen de la simulación. Este dataset se compone de 22 imágenes para cada tipo de señal. La Figura 11 muestra los resultados en forma de matriz de confusión.




Figura 11: Matriz de confusión del test sobre el test del modelo

En esta matriz de confusión, se puede ver que el modelo adivina bien las señales de  $30\text{ km/h}$  y de  $90\text{ km/h}$ , con porcentajes de aciertos igual a un  $86\%$  y un  $81\%$  respectivamente. Estos porcentajes son suficientes, porque en la simulación no se tratan de imágenes aisladas, sino de un flujo video. Entonces se utiliza un filtro para suavizar las predicciones.

En cuanto a la clasificación de las señales de  $60\text{ km/h}$ , los resultados son más bajos, con un porcentaje de aciertos igual a un  $54\%$ . Se observa que el modelo confunde las señales de  $60\text{ km/h}$  con las señales de  $90\text{ km/h}$ . En efecto, un 6 y un 9 son muy parecidos, lo que puede complicar la clasificación de estas señales.

## 4. Integración en simulación y resultados

Esta sección describe cómo los dos módulos de percepción anteriores se integran dentro de un sistema completo que funciona en simulación. Se presentan el entorno de simulación, la arquitectura software basada en ROS2, los nodos que componen el sistema, el controlador del vehículo y los resultados obtenidos.


### 4.1. Entorno de simulación: CARLA Simulator

Para el desarrollo y validación del sistema se ha empleado *CARLA Simulator* (*Car Learning to Act*), un simulador de conducción autónoma de código abierto basado en el motor gráfico *Unreal Engine 4*. CARLA proporciona sensores virtuales de gran fidelidad que permiten probar algoritmos de percepción y control sin necesidad de un vehículo real.

El simulador se ejecuta en su versión *0.9.15* dentro de un contenedor Docker con acceso a la GPU de la máquina anfitriona. Las características más relevantes del entorno configurado son:

- Mapa: Town04, una autopista con señales de tráfico y carreteras con múltiples carriles.
- Vehículo (*ego-vehicle*): modelo basado en Tesla Model 3, controlado desde ROS2.
- Sensores disponibles:
  - Cámara RGB frontal (`rgb_front`): utilizada para detección de carriles y señales.
  - Cámara de segmentación semántica (`semantic_segmentation_front`): empleada para la generación automática de datasets con *ground truth* perfecto.
  - Medidor de velocidad (`speedometer`): velocidad actual del vehículo en m/s.
  - Cámara exterior (`rgb_view`): vista en tercera persona para supervisión visual.

La Figura 12 muestra las dos perspectivas principales disponibles en el simulador.



(a) Vista exterior (tercera persona).

(b) Cámara frontal del vehículo.

Figura 12: Perspectivas en CARLA Simulator. Se aprecia el ego-vehicle tipo Tesla y, en la vista frontal, una señal de límite de velocidad a 90 km/h.

## 4.2. Arquitectura del sistema

El sistema completo se articula en tres capas de software que se comunican entre sí a través de una red Docker en modo *host*:

1. CARLA Simulator: simulador en contenedor Docker independiente con acceso a la GPU.
2. CARLA-ROS2 Bridge: puente oficial que traduce los datos de los sensores de CARLA en tópicos ROS2 estándar y convierte los comandos de control ROS2 en actuaciones sobre el vehículo simulado.
3. Sistema de navegación y percepción: paquete ROS2 propio (`navegacion_deteccion_senales`) que aloja todos los nodos de detección, clasificación y control.

El flujo de información entre los nodos es el siguiente: CARLA publica imágenes en `/carla/ego_vehicle/rgb_front/image` y la velocidad en `/carla/ego_vehicle/speedometer`. El `lane_detection_node` procesa esas imágenes y publica el error lateral en `/lane_detection/lane_error`. El `sign_detection_node` publica el límite de velocidad detectado en `/sign_detection/speed_limit`. El `vehicle_control_node` consume ambos tópicos para calcular y publicar los comandos de control en `/carla/ego_vehicle/vehicle_control_cmd`. Por último, el `annotation_generator_node` agrega toda la información disponible para generar una capa de visualización en tiempo real sobre *Foxglove Studio*.

### 4.3. Infraestructura: Docker y contenedores

Todo el sistema se orquesta mediante **Docker Compose**, levantando tres servicios con un único comando desde la raíz del repositorio:

```
1 xhost +local:docker
2 docker compose -f tools/docker-compose.yaml up
```

La siguiente tabla describe cada uno de los servicios del stack:

| Servicio   | Contenedor                   | Función                               |
|------------|------------------------------|---------------------------------------|
| ros_bridge | carla_ros_bridge             | Bridge CARLA→ROS2                     |
| navegacion | navegacion_deteccion_senales | Lanzamiento del paquete de ROS2       |
| foxglove   | foxglove_bridge              | WebSocket bridge para Foxglove Studio |

La imagen Docker base es `nvidia/cuda:12.8.0-cudnn-runtime-ubuntu22.04`, sobre la que se instalan:

- ROS2 Humble Hawksbill (distribución LTS sobre Ubuntu 22.04).
- PyTorch con soporte CUDA 12.8 para inferencia del clasificador de señales en GPU.
- ONNX Runtime con soporte GPU, para el modelo de detección de carriles.
- Cliente Python de CARLA 0.9.15 y `carla-ros-bridge` compilado desde el código fuente.

El código fuente del paquete ROS2 se monta como volumen dentro del contenedor de navegación, lo que permite que cualquier cambio en el host se aplique de forma inmediata (junto con `colcon build --symlink-install`) sin necesidad de reconstruir la imagen.

### 4.4. Nodos ROS2 del sistema

El paquete `navegacion_deteccion_senales` implementa seis nodos ROS2 en Python que se lanzan mediante el fichero `run.launch.py`.



#### 4.4.1. Nodo de detección de carriles (`lane_detection_node`)

Este nodo recibe cada *frame* de la cámara frontal, ejecuta la inferencia del modelo VGG16-U-Net exportado en formato ONNX y calcula el error lateral del vehículo respecto al centro del carril, expresado en metros. El error se publica en `/lane_detection/lane_error` (Float32) y el estado completo del carril —incluyendo las coordenadas de las líneas izquierda y derecha— se serializa como JSON en `/lane_detection/lane_state`.

#### 4.4.2. Nodo de detección de señales (`sign_detection_node`)

El nodo de señales emplea dos entradas: la imagen RGB de la cámara frontal y la imagen de segmentación semántica del mismo punto de vista. La segmentación semántica identifica con precisión los píxeles correspondientes a señales de tráfico (clase de color amarillo en CARLA), obteniendo *bounding boxes* candidatas que se validan por tamaño (`min_sign_area`: 150 px). Sobre el recorte resultante se ejecuta el clasificador CNN, que determina la etiqueta de la señal (`speed_limit_30`, `speed_limit_60`, `speed_limit_90`) y el límite de velocidad en m/s.

#### 4.4.3. Nodo de control del vehículo (`vehicle_control_node`)

Este nodo cierra el lazo de control: recibe las percepciones de los nodos anteriores y genera los comandos de actuación sobre el vehículo. Opera a 10 Hz e implementa dos controladores PID independientes.

**PID de velocidad (control de cruce).** Regula la velocidad del vehículo en torno a una referencia configurable, inicializada en 2.78 m/s ( $\approx 10$  km/h). Cuando el nodo de señales detecta un límite de velocidad inferior, la referencia se reduce automáticamente. El error de control es la diferencia entre la velocidad objetivo y la velocidad real medida por el odómetro. La salida del PID se mapea a los canales *throttle* y *brake* normalizados en  $[0, 1]$ :

$$\begin{aligned} e_v(t) &= v_{\text{ref}} - v_{\text{actual}} \\ u_v(t) &= K_{p,v} e_v + K_{i,v} \int e_v dt + K_{d,v} \dot{e}_v \\ \text{throttle} &= \text{máx}(0, \text{mín}(1, u_v)), \quad \text{brake} = \text{máx}(0, \text{mín}(1, -u_v)) \end{aligned}$$

**PID de dirección (mantenimiento de carril).** Ajusta el ángulo del volante para mantener el vehículo centrado en el carril. La entrada es el error lateral en metros. Para suavizar la respuesta ante el ruido de la máscara de segmentación, se aplica un filtro paso-bajo de primer orden con coeficiente  $\alpha = 0,05$  antes de alimentar al PID:

$$e_{\text{filt}}[k] = \alpha e_{\text{raw}}[k] + (1 - \alpha) e_{\text{filt}}[k - 1] \quad (1)$$

La salida del PID, en radianes, se normaliza por el ángulo físico máximo del volante ( $\theta_{\text{máx}} = 0,6 \text{ rad} \approx 34 \text{ grados}$ ) para obtener el valor de dirección normalizado de CARLA

en  $[-1, 1]$ . La convención de signo establece que un error positivo (vehículo desplazado a la derecha del carril) genera un giro a la izquierda (dirección negativa).

Ambos PIDs incorporan anti-windup que limita el término integral al rango  $[-10, 10]$ . Los parámetros finales configurados en `params.yaml` se recogen en la Tabla 2.

Cuadro 2: Parámetros de los controladores PID (`params.yaml`).

| Parámetro                  | Valor          | Descripción                             |
|----------------------------|----------------|-----------------------------------------|
| <code>control_rate</code>  | 10 Hz          | Frecuencia del bucle de control         |
| <code>target_speed</code>  | 2.78 m/s       | Velocidad objetivo ( $\approx 10$ km/h) |
| <code>kp_throttle</code>   | 0.30           | Ganancia proporcional de velocidad      |
| <code>ki_throttle</code>   | 0.05           | Ganancia integral de velocidad          |
| <code>kp_steering</code>   | 0.20 rad/m     | Ganancia proporcional de dirección      |
| <code>ki_steering</code>   | 0.02 rad/(m·s) | Ganancia integral de dirección          |
| <code>kd_steering</code>   | 0.10 rad·s/m   | Ganancia derivativa de dirección        |
| <code>max_steer_rad</code> | 0.6 rad        | Ángulo físico máximo del volante        |

#### 4.4.4. Nodo generador de anotaciones (`annotation_generator_node`)

Este nodo actúa como capa de visualización del sistema. En cada *frame* de la cámara frontal, recoge el estado de todos los demás nodos y genera un mensaje `foxglove_msgs/ImageAnnotations` que Foxglove Studio superpone sobre la imagen en tiempo real. Las anotaciones incluyen:

- Polígono de carril: región semitransparente en verde que cubre el área entre las líneas izquierda y derecha del carril.
- Líneas de carril: línea izquierda en amarillo y derecha en cian, con grosor de 6 px.
- Vector de desviación: segmento del centro de la imagen al centro del carril estimado; verde si el error es menor de 30 px, rojo si es mayor.
- Bounding box de señal: rectángulo con esquinas decorativas y etiqueta de texto; naranja para límites de velocidad, rojo para señales de stop.
- HUD de telemetría: textos con el error lateral (m y px), la velocidad actual (km/h) y los valores de *throttle*, *brake* y *steer*.

La Figura 13 muestra la interfaz de Foxglove Studio.



Figura 13: Interfaz de Foxglove Studio durante una sesión de conducción autónoma.

#### 4.5. Generación de datasets sintéticos

Una de las ventajas de trabajar con un simulador como CARLA es la posibilidad de generar datos etiquetados de forma automática. La cámara de segmentación semántica asigna a cada píxel una etiqueta de clase con precisión perfecta, ofreciendo un *ground truth* ideal para entrenar y validar los modelos de percepción sin ningún coste de anotación manual.

El paquete implementa dos nodos de recolección que operan en modo conducción manual (sin `vehicle_control_node`) a una cadencia de 5 Hz:

**Dataset de carriles (`lane_dataset_node`).** Detecta las marcas viales en la máscara semántica, las proyecta al espacio RGB y almacena en `dataset/lanes/` pares de imagen RGB y máscara binaria de *ground truth*.

**Dataset de señales (`sign_dataset_node`).** Localiza los píxeles de señales (color amarillo en CARLA), extrae bounding boxes y almacena en `dataset/signs/` las imágenes RGB junto con ficheros JSON de anotaciones.

Las composiciones Docker para la recolección están en `tools/docker-compose-lane-dataset.yaml` y `tools/docker-compose-sign-dataset.yaml`. El repositorio incluye también herramientas de visualización (`visualize_lanes_dataset.py`, `visualize_signs_dataset.py`) y scripts de anotación manual (`annotate_signs_dataset.py`, `label_signs_dataset.py`) para enriquecer el dataset sintético con etiquetas adicionales. Las animaciones del pro-

ceso de generación de datos (`Lanes_Dataset.gif` y `Signs_Dataset.gif`) están disponibles en el repositorio de GitHub.

## 4.6. Resultados

### 4.6.1. Rendimiento en tiempo real

La siguiente tabla recoge los tiempos de procesamiento medidos durante las sesiones de conducción autónoma en el simulador.

| Módulo                | Latencia media  | Frecuencia efectiva |
|-----------------------|-----------------|---------------------|
| Detección de carriles | $\approx 50$ ms | $\approx 20$ fps    |
| Detección de señales  | $\approx 13$ ms | $\approx 77$ fps    |

Ambas latencias se sitúan bien por debajo del período del controlador (100 ms a 10 Hz), lo que garantiza que los comandos de actuación siempre disponen de percepciones actualizadas.

### 4.6.2. Entorno de pruebas

Las pruebas se han realizado sobre el siguiente entorno hardware y software:

- CPU: Intel Core i7-13620H.
- GPU: NVIDIA GeForce RTX 5070 para portátiles.
- Sistema operativo: Ubuntu 22.04 (contenedor Docker).
- Framework: ROS2 Humble Hawksbill.
- Simulador: CARLA 0.9.15.

### 4.6.3. Conducción autónoma en simulación

El sistema completo mantiene el vehículo dentro del carril de forma continuada a velocidades de hasta 30 km/h, adaptando la velocidad cuando detecta señales de límite, pero escaladas a un tercio (i.e. 90 km/h pasa a ser 30 km/h). El vídeo demostrativo del sistema funcionando en tiempo real (`media/Demo.mp4`) está disponible en el repositorio de GitHub:

<https://github.com/JoseLopez36/Navegacion-Deteccion-Senales>

## 5. Conclusiones

Este trabajo ha permitido diseñar e integrar un sistema de percepción completo para la conducción autónoma en simulación, demostrando que la combinación de modelos de *deep learning* con una arquitectura ROS2 modular es una solución eficaz y reproducible. Los resultados obtenidos confirman que el sistema opera en tiempo real con latencias bajas y es capaz de mantener el vehículo dentro del carril mientras respeta los límites de velocidad detectados.